



IMPLÉMENTEZ UN MODÈLE DE SCORING

FORMATION DATA SCIENTIST – PROJET 7

OCTAVE POUILLOT

AOUT 2023

SOMMAIRE

- Mission & Dataset
- Architecture globale
- Modélisation
 - Démarche
 - MLFlow
 - Résultats
- Déploiement
 - API
 - Dashboard
- Data Drift
- Démonstration





MISSION

• Société financière "Prêt à dépenser", propose des crédits à la consommation pour des personnes ayant peu ou pas d'historique de prêt.

Objectifs:

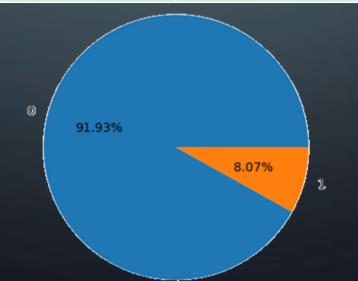
- Construire un modèle de scoring pour prédire la probabilité de faillite d'un client
- Construire un dashboard interactif pour les gestionnaires de la relation client
- Mettre en production le modèle de scoring à l'aide d'une API, ainsi que le dashboard interactif qui appelle l'API pour les prédictions

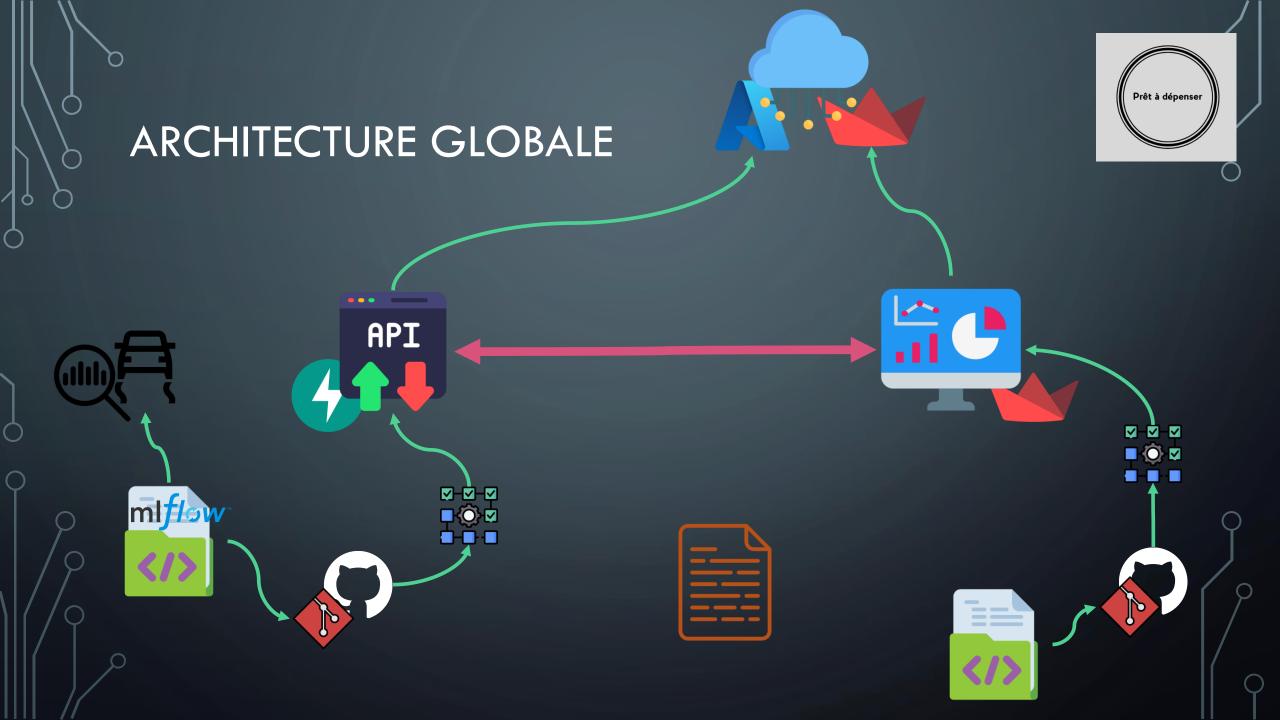


DATASET

Deux dataset utilisés, disponible sur Kaggle :

Application_train	Application_test
Avec target	Sans target
307 511 lignes (clients)	48 744 lignes (clients)
122 features	121 features





Prêt à dépenser API mlflow

MODÉLISATION

DÉMARCHE

MLFLOW

RÉSULTATS





- Utiliser et adapter des kernel Kaggle
 - analyse exploratoire
 - préparation des données
 - feature engineering
- Kernel utilisés :
 - credit-default-risk
 - predict-score-credit

- Equilibrage:
 - Smote
 - class_weight
- Métriques :
 - Job_score = (10 * FNR) + FPR
 - ROC AUC
 - Training time
- Score Global:
 time + 2 * roc auc + 2 * job_score





1ère sélection

- Logisitc Regression
- Decision Tree
- Linear Discriminant Analysys
- Gradient Boosting
- XGBoost
- LigthBoost
- Adaboost
- Random Forest

Optimisation

- Hyperparamètres
- Pipeline
- GridSearch
- CrossValidation
- Calcul scores
- Logisitc Regression
- XGBoost
- LigthBoost

Analyse

- Interprétabilité
- Comparaison score

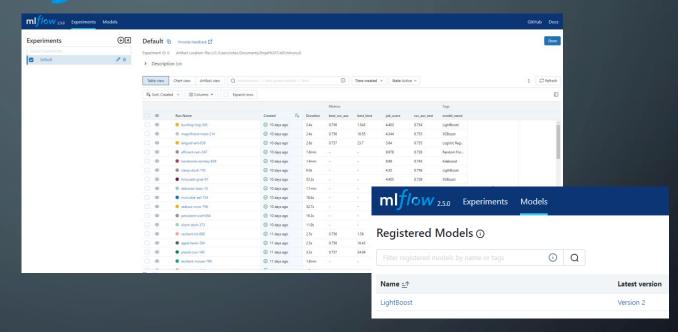
Sélection du modèle

- Calcul du score global
- Enregistrement du modèle automatique





- Fonction tracking:
 - Model
 - Metrics
- Fonction Register:
 - Save model

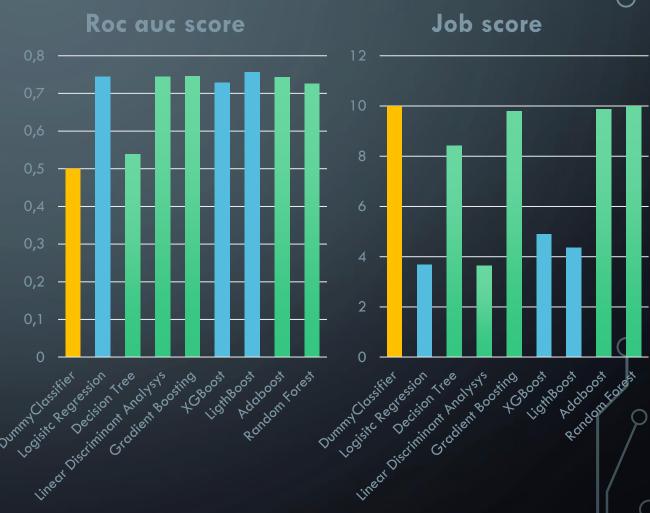


Serveur et stockage en local



MODÉLISATION - RÉSULTATS

Model Name	Roc auc score	Job score	Time
DummyClassifier	0.5	10	11.9s
Logisitc Regression	0.744	3.687	16.3s
Decision Tree	0.539	8.41	32.7s
Linear Discriminant Analysys	0.745	3.636	18.4s
Gradient Boosting	0.746	9.794	1.1 min
XGBoost	0.729	4.905	53.3s
LigthBoost	0.756	4.35	6.0s
Adaboost	0.743	9.88	1.4min
Random Forest	0.726	9.978	1.8min

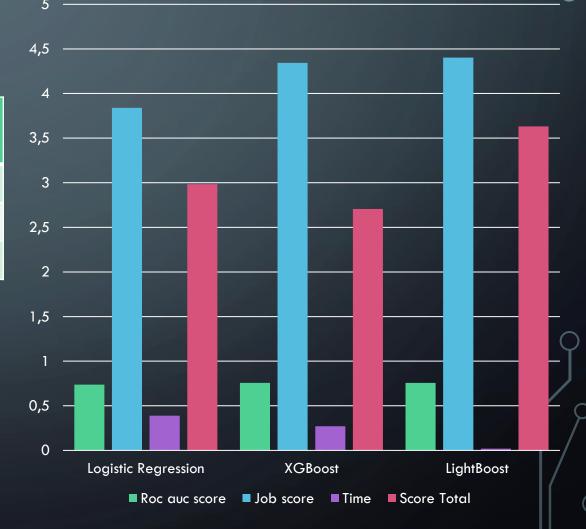


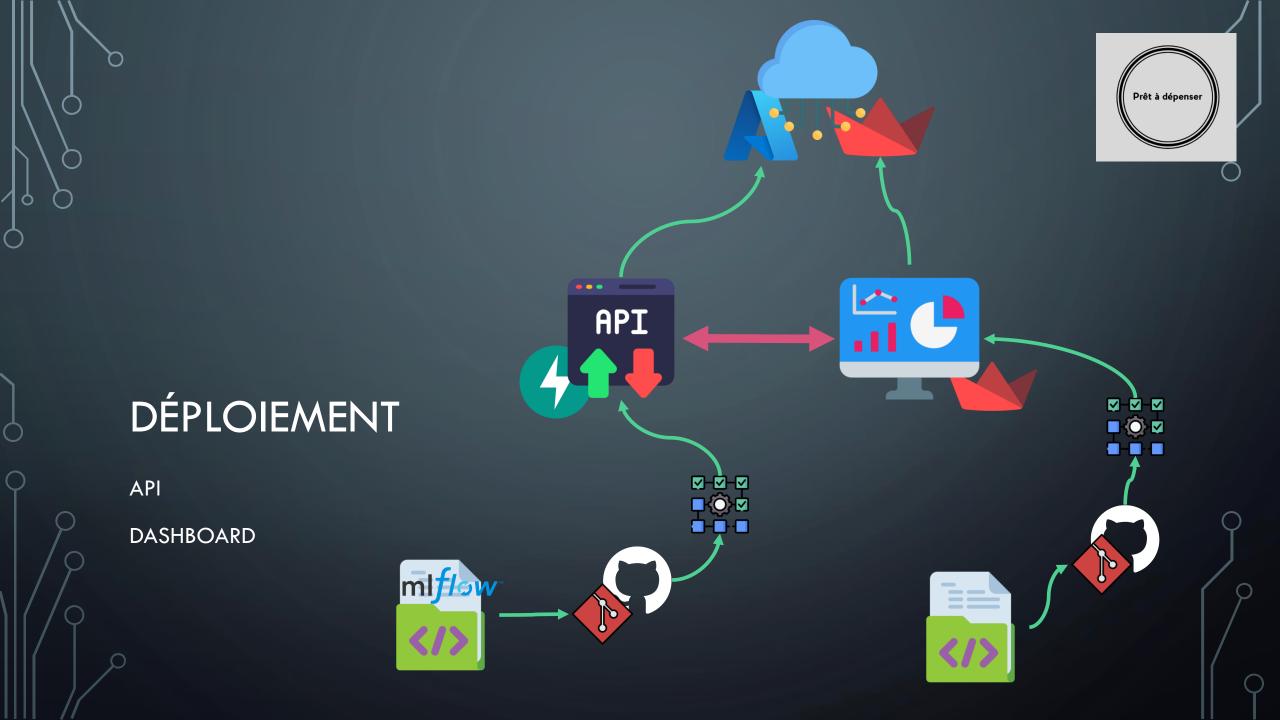
MODÉLISATION - RÉSULTATS

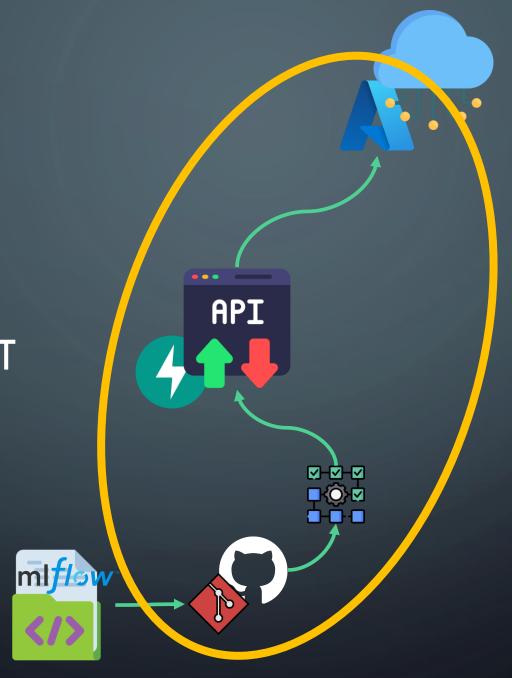
Model Name	Roc auc score	Job score	Time	Score Total
Logistic Regression	0.737	3.84	23.7	2.983
XGBoost	0.756	4.344	16.55	2.706
LightBoost	0.756	4.403	1.543	3.632













DÉPLOIEMENT API

FASTAPI

GITHUB

PYTEST

ACTIONS

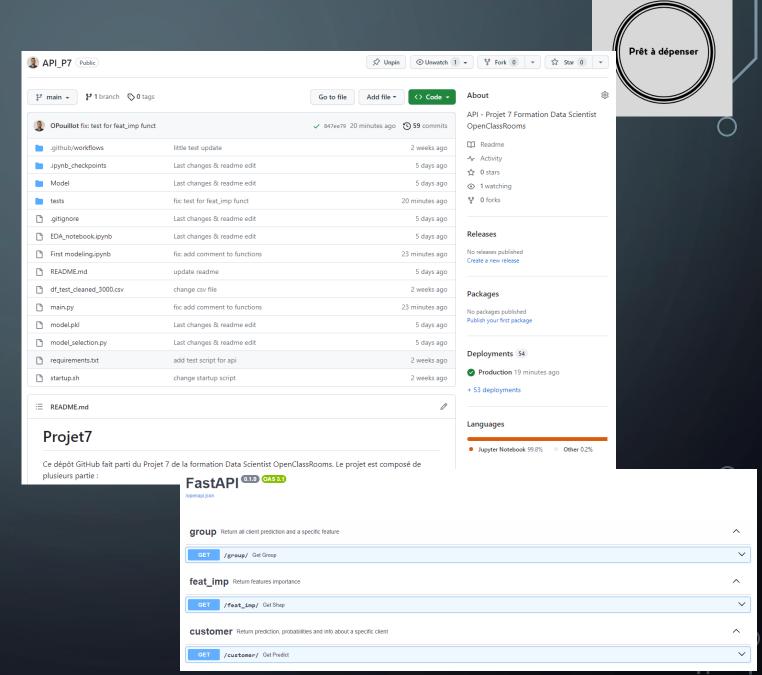
AZURE

DÉPLOIEMENT - API

- FastAPI:
 - Chargement des données
 - Chargement du model
 - 3 Fonctions

Pytest

GitHub



DÉPLOIEMENT - API

Summary

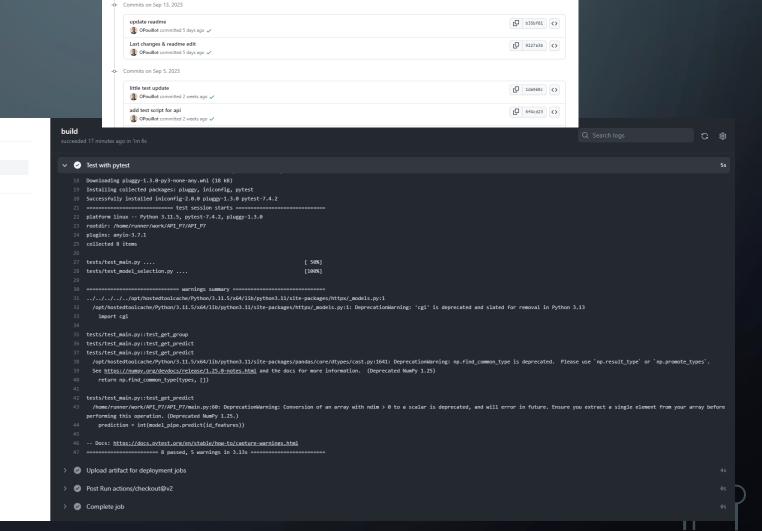
deploy

Run details

🖔 Usage

GitHub Actions

- Build
 - Install env
 - Tests
- Deploy
 - if build passed
 - Azure deploy



Prêt à dépenser

₽ 847ee79 ⟨>

☐ 4c77afd ⟨>

Commits

្ងៃ main ▼

-O- Commits on Sep 18, 2023

fix: test for feat_imp funct

OPoullot committed 17 minutes ago
 fix: add comment to functions

OPouillot committed 20 minutes ago X

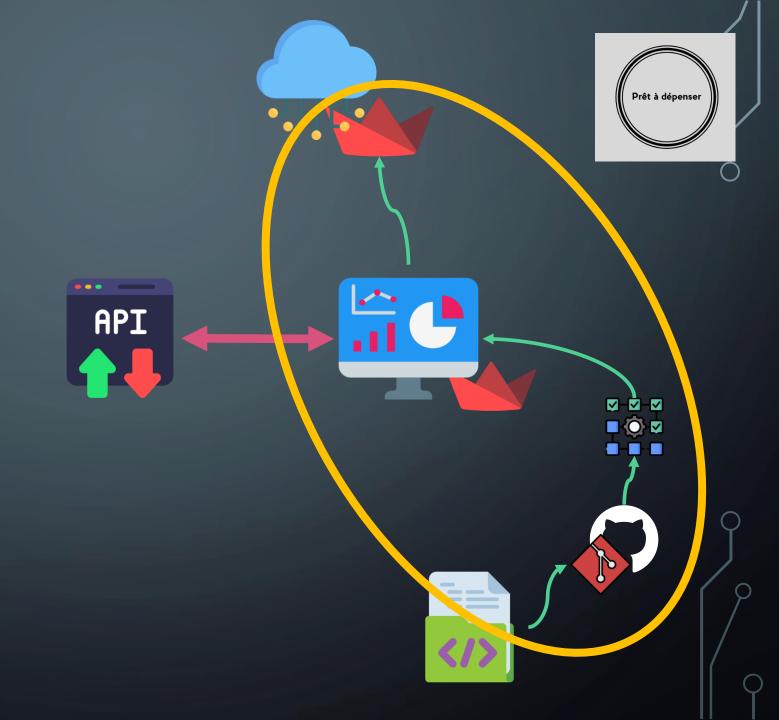
DÉPLOIEMENT DASHBOARD

STREAMLIT

GITHUB

PYTEST

ACTIONS

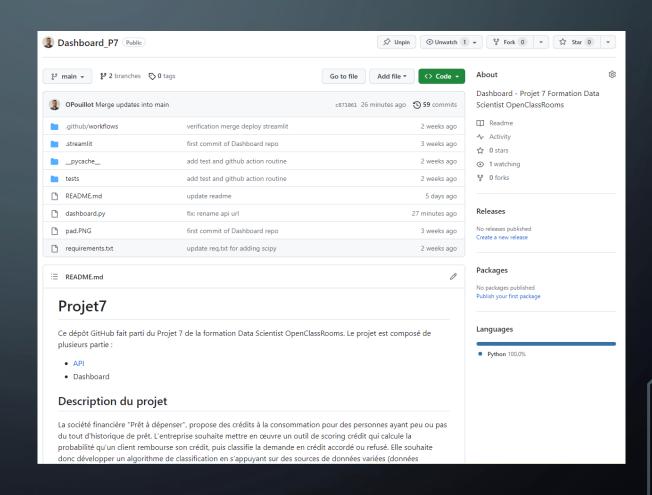




DÉPLOIEMENT - DASHBOARD

- Streamlit:
 - Info prêt
 - Données client
 - Ensemble clients
- Pytest

• GitHub

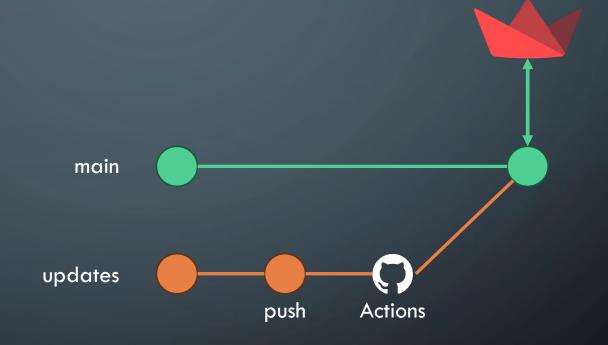






Push updates:

- Build
 - Install env
 - Tests
- Merge on main
 - if build passed



Prêt à dépenser API DATA DRIFT EVIDENTLY AI ml*fls*w



DATA DRIFT

- Dataset train et test cleaned (207 features)
- Sample: 10 000
- Drift: 5.8% du dataset (12 features)
- Niveau de vie et pouvoir d'achat
 - revenus annuels
 - Crédit demandé
 - Patrimoine
 - ..
- Seuil maximum → actualiser la modélisation par rapport à des variables comme l'inflation et le PIB.

	Column	Туре	Reference Distribution	Current Distribution	Data Drift	Stat Test	Drift Score
>	DEBT_TO_INCOME_RATIO	num	L	L	Detected	Wasserstein distance (normed)	0.292271
>	INCOME_TO_CREDIT	num	<u></u>	L	Detected	Wasserstein distance (normed)	0.278425
>	AMT_GOODS_PRICE	num	I	I	Detected	Wasserstein distance (normed)	0.221456
>	AMT_CREDIT	num	II	II	Detected	Wasserstein distance (normed)	0.218926
>	FLAG_DOCUMENT	num		LI	Detected	Jensen-Shannon distance	0.164015
>	EXT_SOURCE_1	num			Detected	Wasserstein distance (normed)	0.157719
· ·	NAME_CONTRACT_TYPE_Cash loans	num	..		Detected	Jensen-Shannon distance	0.151032
>	NAME_CONTRACT_TYPE_Revolving loans	num	I		Detected	Jensen-Shannon distance	0.151032
· ·	AMT_ANNUITY	num		I.	Detected	Wasserstein distance (normed)	0.148694
>	FLAG_EMAIL	num	I	Ī	Detected	Jensen-Shannon distance	0.128973
>	DAYS_LAST_PHONE_CHANGE	num			Detected	Wasserstein distance (normed)	0.120622
>	AMT_INCOME_TOTAL	num	L	I	Detected	Wasserstein distance (normed)	0.115021



DÉMONSTRATION!

- → VERS LE <u>DASHBOARD</u>
- → VERS L'<u>API</u>

