



# DÉPLOYEZ UN MODÈLE DANS LE CLOUD

FORMATION DATA SCIENTIST - PROJET 8

**OCTAVE POUILLOT** 

OCTOBRE 2023





- Mission & Dataset
- Environnement Big Data
- Preprocessing
- Démonstration
- Conclusion



#### MISSION

- Data Scientist dans la start-up de l'AgriTech "Fruits!", qui cherche à proposer des solutions innovantes pour la récolte des fruits.
- Se faire connaître par une application mobile permettant de prendre en photo un fruit et d'obtenir des informations sur ce fruit.

#### Objectifs:

- S'approprier les travaux réalisés par l'alternant
- Compléter la chaîne de traitement
- Mettre en œuvre une architecture Big Data





#### Images de fruits:

- 90483 images
- 67692 images train / 22688 images test
- 131 classes (variétés de fruits)

• Dossier "Test1" de 30 images, 3 fruits (banane, citron, pomme)







MACHINE VIRTUEL

ARCHITECTURE GLOBALE

IAM / S3 / EMR

TUNNEL SSH



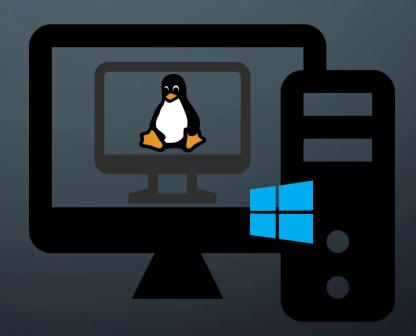




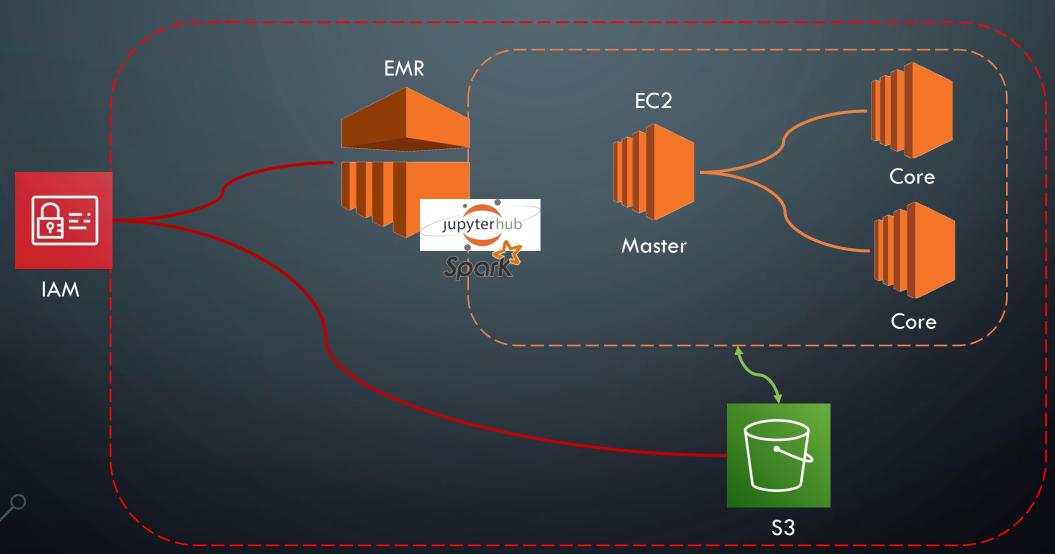




- Virtual Box
- Linux Ubuntu
- Installation:
  - Pip
  - Spark
  - Jupyter
  - Aws cli











- Root user
  - All access
  - Gestion EMR
- UserP8
  - \$3 Full Access
  - AWS CLI
  - Génération de clés SSH
- OPouillotP8Evaluator
  - S3 Read Access





- Définition de la région sur Paris (eu-west-3)
- Création d'un bucket « p8octave-dataset »
- Copie des données « Test1 »

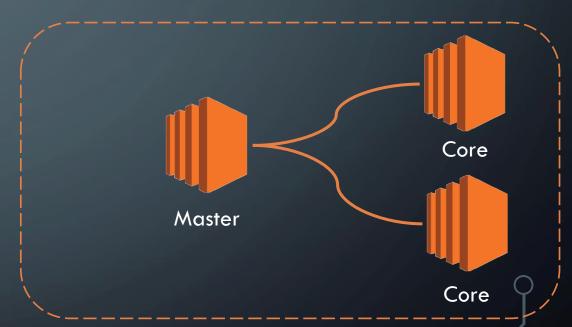
aws s3 mb s3://p8octave-dataset

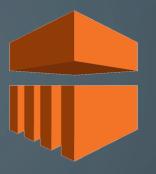
aws sync . s3://p8octave-dataset /Test





- Région : Paris (eu-west-3)
- Applications
  - Spark
  - JupyterHub
  - Tensorflow
- Instances cóg.xlarge (\$)
- Résiliation auto : 1h

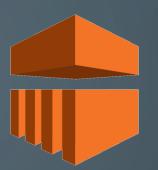




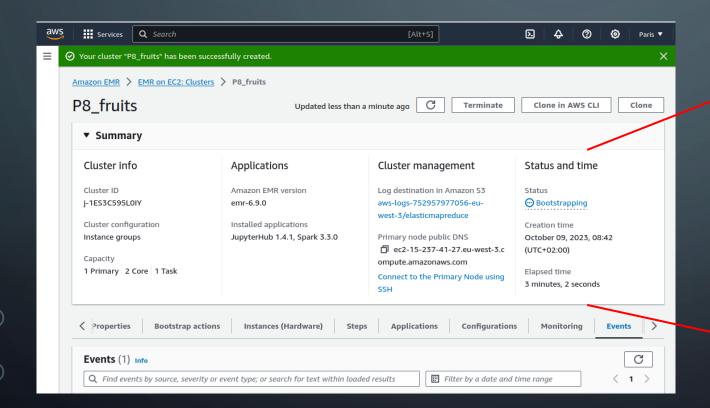


- Création d'un fichier Bootstrap :
  - Upgrade setuptools & pip
  - Installation des librairies nécessaires
    - + Tensorflow
- Clés SSH EC2









#### Status and time

#### Status



Creation time

October 09, 2023, 08:42

(UTC+02:00)

Elapsed time

6 minutes, 59 seconds

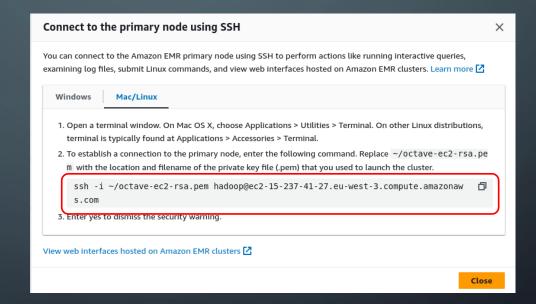






Connexion SSH

• -D 5555

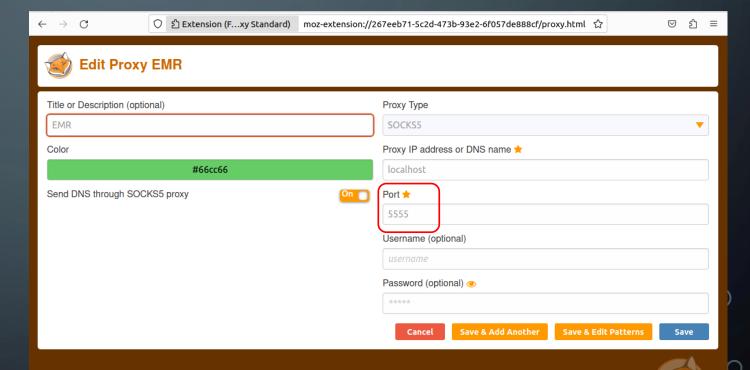








Paramétrage de FoxyProxy

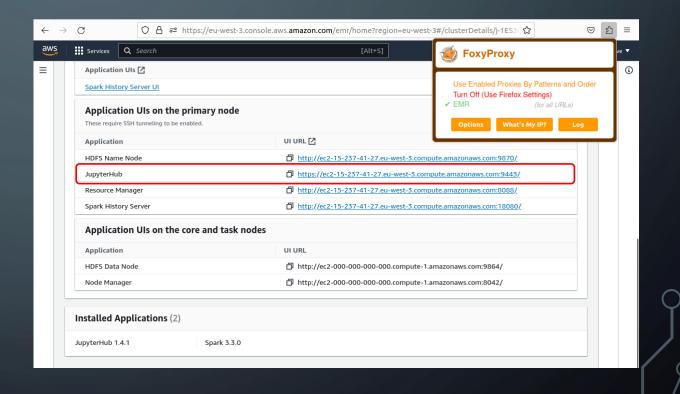








- Connexion à JupyterHub
- Upload du notebook
- Kernel PySpark





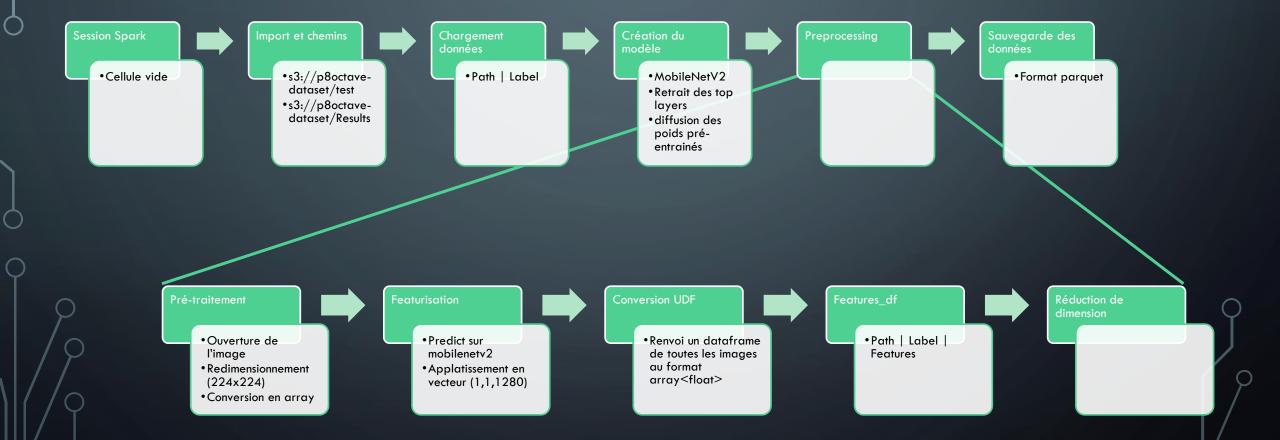
## PREPROCESSING

ETAPES GÉNÉRALE

PREPROCESSING



#### PREPROCESSING



#### PREPROCESSING

```
In [*]: # Appliquer la conversion à la colonne 'features'
features_df = features_df.withColumn('features', array_to_vector(features_df['features']))

# Standardisation
scaler = StandardScaler(inputCol="features", outputCol="scaled_features")

# PCA
pca = PCA(k=2, inputCol="scaled_features", outputCol="pca_features")

# Création du pipeline
pipeline = Pipeline(stages=[scaler, pca])

# Application du pipeline sur le DataFrame
model = pipeline.fit(features_df)
result = model.transform(features_df)

# Sélection des colonnes
result = result.select("path", "label", "pca_features")

# Convertion des vecteurs en listes Python
features_df = result.withColumn("pca_features", vector_to_list("pca_features"))

Progress:
```



Conversion ( features ) array

vector



Définition StandardScaler



**Définition PCA** 



Définition pipeline



Application du pipeline sur (( features ))



Création d'un dataframe ( path | label | pca\_features )



Conversion ( pca\_features ) vector 

list





# DÉMONSTRATION!





# CONCLUSION





- Mise en place d'un environnement Big Data
- Lancement d'un notebook via JupyterHub
- PCA via PySpark
- → PoC valide



- Entrainement et évaluation du modèle
- Déploiement du modèle dans le cloud
- Scaling automatique via EMR

